



**Université
de Rennes**



Étude des méthodes d'estimations de la matrice de covariance et de l'impact sur ses valeurs propres : application à la gestion de portefeuille et à la géométrie des surfaces

Joanna MONCELET

Université de Rennes
Univeristé de Rennes 2
Promotion 2025/2026
Période du stage : du 04/05/26 au 19/06/26
Tuteur universitaire : Auréline Fargeas

Organisme d'accueil :
Université Clermont-Auvergne
LIMOS UMR 6158
1 rue de la Cherbarde

Tuteur :
Fabien FESCHET, Professeur des universités

Remerciements

Je tiens à remercier l'ensemble du personnel du LIMOS et le service MAAD pour leur accueil et leur sympathie. Plus particulièrement je remercie mon tuteur, Monsieur Fabien Feschet, pour sa confiance et ses conseils tout au long de mon stage. Merci aux autres stagiaires du laboratoire pour leur accompagnement.

Table des matières

1	Introduction	3
2	Présentation de l'organisme d'accueil	4
2.1	Le LIMOS	4
2.2	L'équipe MAAD	4
2.3	La mission	5
3	Description et exécution de la mission	6
3.1	Planning de la mission	6
3.2	Déroulé de la mission	6
3.2.1	Expérience 1	6
3.2.2	Expérience 2	8
3.2.3	Expérience 3	10
3.2.4	Expérience 4	13
4	Bilan du stage	16
4.1	Utilité	16
4.2	Apports	16
5	Conclusion	17

1 Introduction

Dans le cadre de ma dernière année de licence de Mathématiques et Informatique Appliquées aux Sciences Humaines et Sociales (MIASHS) à l'Université de Rennes et l'Université de Rennes 2, j'ai effectué un stage de 7 semaines, du 4 mai au 19 juin 2026, au sein du Laboratoire d'Informatique, de Modélisation et d'Optimisation des Systèmes (LIMOS), à Clermont-Ferrand.

Voulant m'orienter vers la recherche en mathématiques, il me semblait important de faire ce stage dans un laboratoire pour découvrir ce milieu, voir comment ça fonctionne au quotidien, et échanger avec des enseignants-chercheurs. J'ai contacté plusieurs laboratoires dans différentes villes, et c'est finalement le LIMOS qui a répondu positivement. Le sujet proposé m'a tout de suite parlé.

Ce stage porte sur l'étude des méthodes d'estimation de la matrice de covariance et de l'impact sur ses valeurs propres, avec deux applications : la gestion de portefeuille et la géométrie des surfaces. C'est un sujet qui associe les mathématiques à des applications concrètes en finance, ce qui correspondait bien à mes intérêts. Faisant partie du parcours Science des données, Statistique et Économétrie de ma licence MIASHS, je suis en effet intéressée par l'économie en plus des mathématiques. Ce stage était donc une bonne façon de travailler sur les deux à la fois.

Ce rapport est organisé en trois parties. La première présente l'organisme d'accueil et la mission qui m'a été confiée. La deuxième décrit le travail que j'ai réalisé durant ces 7 semaines. Enfin, la troisième partie revient sur ce que ce stage m'a apporté.

Le lien vers le dépôt GitHub du stage se trouve en annexe.

2 Présentation de l'organisme d'accueil

2.1 Le LIMOS

Le Laboratoire d'Informatique, de Modélisation et d'Optimisation des Systèmes (LIMOS) est une Unité Mixte de Recherche (UMR 6158) qui travaille en informatique et plus largement dans le domaine des Sciences et Technologies de l'Information et de la Communication (STIC). Créé en 1995, il est passé par plusieurs statuts avant de devenir une UMR en 2002.

Basé sur le campus scientifique de l'Université Clermont-Auvergne (UCA), le laboratoire s'est aussi développé sur le site de Saint-Étienne en 2010, en accueillant des chercheurs de l'École des Mines de Saint-Étienne (EMSE). Le laboratoire est rattaché au CNRS, à l'UCA et à l'EMSE, avec Clermont Auvergne INP comme tutelle secondaire.

Le LIMOS compte 208 membres (98 enseignants-chercheurs et chercheurs, 68 doctorants, 15 postdoctorants, 4 professeurs émérites, 4 ATER, 8 personnels d'appui à la recherche, 10 ingénieurs/techniciens/administratifs et 1 maître assistant), et occupe une place importante dans la recherche en informatique à Clermont-Ferrand. Il participe notamment au projet I-Site CAP2025 et au Centre International de Recherche ITPS (Innovative Transportation and Production Systems), où il dirige le thème "Services Innovants". Le laboratoire fait également partie du laboratoire commun FACTOLAB, monté avec Michelin, et dirige GDR MaDICS.

Le LIMOS est organisé en 3 axes scientifiques :

- MAAD : Modèles et Algorithmes de l'Aide à la Décision
- SIC : Systèmes d'Information et de Communication
- ODPS : Outils Décisionnels pour la Production et les Services

Ces axes regroupent de nombreuses thématiques de recherche, comme l'algorithmique et la théorie des graphes, le traitement des données et l'intelligence des services, l'optimisation des systèmes manufacturiers, la conception de services, la métamodélisation, les réseaux et la sécurité, ou encore l'optimisation combinatoire.



2.2 L'équipe MAAD

J'ai effectué mon stage au sein de l'axe MAAD (Modèles et Algorithmes de l'Aide à la Décision), dirigé par Rodolphe Le Riche et Mamadou Kanté.

Cette équipe s'intéresse à des problèmes de décision qui peuvent venir de plusieurs domaines comme l'informatique, l'industrie, la gestion, l'économie, le traitement d'images, la bio-informatique, etc. Concrètement, les chercheurs de MAAD travaillent sur l'optimisation combinatoire et continue, la théorie des graphes et hypergraphes, la complexité algorithmique, ainsi que la métamodélisation appliquée à l'optimisation.

L'équipe MAAD est rattachée à 3 thèmes de recherche :

- Algorithmique, Graphes, Complexité
- Métamodélisation, Optimisation Continue et Applications (MOCA)
- Optimisation Combinatoire

2.3 La mission

Mon stage au sein du LIMOS porte sur les méthodes d'estimation de la matrice de covariance, et sur la manière dont ces méthodes influencent ses valeurs et vecteurs propres. Ce travail touche à deux domaines plutôt différents : la gestion de portefeuille en finance, et la géométrie des surfaces.

En finance, la bonne estimation des matrices de covariance est très importante, et on peut le voir avec la théorie moderne du portefeuille (MPT) de Markowitz [5]. Le principe du MPT est de chercher, parmi tous les portefeuilles d'actifs possibles, ceux qui forment la frontière efficiente (ceux qui maximisent le rendement espéré pour un niveau de risque donné, et inversement). Trouver cette frontière revient à résoudre un problème d'optimisation sous contrainte (minimiser le risque $w^T \Sigma w$ pour un rendement cible donné), dont la résolution via le lagrangien fait intervenir l'inverse de la matrice de covariance, Σ^{-1} (la matrice de précision). Seulement, si Σ est mal estimée, son inverse Σ^{-1} amplifie énormément les erreurs, et cela se traduit par des portefeuilles optimaux très peu fiables.

De plus quand on construit un portefeuille avec plusieurs actifs, ces actifs n'ont pas forcément tous la même durée d'historique [1] [7], et avec l'estimation empirique classique, on ne peut pas exploiter toutes les données disponibles.

C'est ce genre de problèmes que le shrinkage [4][3], étudié dans ce stage, cherche à corriger.

"La deuxième partie du stage est plus géométrique : on s'intéresse à l'impact des méthodes d'estimation sur les valeurs et vecteurs propres de la matrice de covariance. En effet, le vecteur propre associé à la plus petite valeur propre de la matrice de covariance donne une direction normale à un ensemble de points sur une surface. Le but est donc de voir comment les différentes méthodes d'estimation changent ces directions et de le visualiser en 3D.

3 Description et exécution de la mission

3.1 Planning de la mission

Pendant ce stage mon travail était divisé en 4 expériences, organisées de façon progressive. Je suis partie d’une prise en main des valeurs propres et vecteurs propres d’une matrice de covariance sur des cas simples, pour comprendre l’aspect géométrique du sujet, avant de passer à des cas plus réalistes avec du bruit et des nuages de points 3D. J’ai poursuivi avec des méthodes de régularisation par shrinkage, avec notamment l’estimateur de Ledoit-Wolf [2], appliquées à la géométrie des surfaces et à la gestion de portefeuille via la théorie de Markowitz [5]. Enfin j’ai abordé le cas plus concret des matrices d’actifs aux durées d’historique différentes.

Pour chaque expérience, je suis passée par une phase de recherche avec la lecture d’articles pour me familiariser avec les nouvelles notions, puis une phase d’implémentation en R, et enfin des échanges avec mon tuteur pour vérifier les résultats, voir les pistes d’amélioration et ajuster le travail.

3.2 Déroulé de la mission

Les sous-sections suivantes décrivent chacune des 4 expériences.

3.2.1 Expérience 1

La 1^{ère} expérience avait pour objectif de comprendre comment l’estimation d’une matrice de covariance évolue selon la taille de l’échantillon utilisé. Je disposais d’une série de 200 000 observations de log-rendements pour 20 actifs et d’une matrice de référence C^* fournie séparément.

Tout au long de ce stage je me suis basée sur l’hypothèse de normalité de mes données. J’ai donc vérifié que celles-ci suivent approximativement une loi normale en traçant la densité empirique des log-rendements (Figure 1) qui donnent bien une forme de cloche.




FIGURE 1 – Densité empirique des log-rendements $\log(1 + r)$ - actif 1

J’ai ensuite codé la matrice de covariance empirique avec la formule analytique, et vérifié qu’elle coïncidait avec la fonction `cov()` de R. Pour comparer $\text{cov}_{emp}(E)$ à C^* , j’ai mis en place deux indicateurs : la norme de Frobenius, définie par :

$$\|A\|_F := \sqrt{\sum_{i,j} |A_{ij}|^2} = \sqrt{\text{tr}(A^\top A)}$$

qui donne une mesure globale de l’écart entre les deux matrices, terme à terme ; et l’erreur relative, qui normalise cette distance par $\|C^*\|$ pour avoir un résultat indépendant de l’échelle des données.

J’ai ensuite étudié la variabilité de $\text{cov}_{emp}(E)$ avec n fixé ($n = 200$) via deux méthodes de rééchantillonnage :

1. Le bootstrap, qui tire B échantillons de taille n avec remise depuis l’échantillon original, calcule cov_{emp} sur chacun, et permet d’estimer la variabilité de cet estimateur à partir de la dispersion des B matrices obtenues.

2. Le jackknife qui retire une observation à la fois. À partir de l'échantillon $E = (E_1, \dots, E_n)$, il construit les n sous-échantillons $E^{(-i)}$ de taille $n - 1$ obtenus en retirant la i^e observation, et calcule $\text{cov}_{emp}(E^{(-i)})$ pour chacun. On obtient ainsi une estimation de la variabilité de $\text{cov}_{emp}(E)$

Finalement, en faisant varier n de 2 à 200 000, on observe une convergence claire de $\text{cov}_{emp}(E)$ vers C^* illustrée en Figure 2 : l'erreur relative décroît rapidement avec n , ce qui confirme que l'estimateur devient de plus en plus fiable quand l'échantillon grandit.




FIGURE 2 – Erreur relative $\|\text{cov}_{emp}(n) - C^*\|/\|C^*\|$ en fonction de n

3.2.2 Expérience 2

La 2^{ème} expérience portait sur l'étude des valeurs propres et vecteurs propres d'une matrice de covariance.

L'idée était de fixer un point P et de construire un vecteur normal aléatoire $n = (a, b, c)$, normalisé et de composantes $a > b > c > 0$. Ce vecteur définissait un plan affine $\mathbb{P}$ passant par P . Pour construire une base de ce plan, j'ai projeté les points $P + e_k$ (où e_k sont les vecteurs canoniques) sur $\mathbb{P}$, et j'ai retenu celui dont la projection avait la norme maximale. J'ai pu obtenir le vecteur unitaire v_1 en normalisant le vecteur reliant P à cette projection, et v_2 par le produit vectoriel $n \times v_1$. J'avais donc une base orthonormée (v_1, v_2, n) .

Une fois cette base construite, j'ai généré une grille de points $(X, Y) = (ih, jh)$ pour i, j entiers dans un intervalle donné (ici, $[-5, 5]$), et j'ai construit les points avec $M = P + X v_1 + Y v_2 + f(X, Y) n$, avec f une fonction test (uniforme, eggholder, McCormick, etc.). $f(X, Y) n$ représentait l'écart du point par rapport au plan $\mathbb{P}$, dans la direction normale.

J'ai ensuite calculé la matrice de covariance du nuage de points M obtenu, ainsi que ses valeurs propres et vecteurs propres. J'ai vérifié que les deux premiers vecteurs propres vp_1 et vp_2 (associés aux deux plus grandes valeurs propres) sont bien situés dans le plan $\mathbb{P}$, donc orthogonaux à n , et que le troisième vecteur propre vp_3 est aligné avec n .

Pour visualiser la part de variance expliquée par chaque composante, j'ai tracé le screeplot de la matrice de covariance (Figure 3). Le screeplot représente les valeurs propres classées par ordre décroissant. Il permet de visualiser quelle part de la variance totale du nuage est expliquée par chaque direction. C'est directement lié à l'analyse en composantes principales (ACP) : la diagonalisation de la matrice de covariance nous dit que le premier vecteur propre est la direction qui explique le plus de variance, le deuxième explique la plus grande part de la variance restante, et ainsi de suite. Dans notre cas, $\lambda_3 \approx 0$ signifie que le nuage est quasiment plat dans la direction normale, ce qui confirme que $vp_3 \approx n$.




FIGURE 3 – Screeplot avec la fonction Eggholder

J'ai aussi étudié le cas particulier où l'amplitude de $f = 0$: tous les points sont dans le plan $\mathbb{P}$, et $\lambda_3 \approx 0$ puisqu'il n'y a pas de variance dans la direction normale.

Enfin, j'ai regardé l'effet de l'amplitude de f sur l'alignement de vp_3 avec n . En effet plus l'amplitude augmente, plus le produit scalaire $\langle vp_3, n \rangle$ diminue, ce qui provoque un décalage entre vp_3 et n .

Pour la partie visualisation, j'ai utilisé **rgl** (Figure 4) pour représenter en 3D le nuage de points, le plan $\mathbb{P}$, le point P , la normale n , la base (v_1, v_2) ainsi que les trois vecteurs propres.

Pour finir cette expérience, j'ai réalisé une visualisation complémentaire en 3D (Figure 5) : un nuage de points tirés uniformément à l'intérieur d'un ellipsoïde, via la méthode *test and reject*. Sachant qu'un ellipsoïde de demi-axes $a, b, c > 0$ est défini par

$$\frac{x^2}{a^2} + \frac{y^2}{b^2} + \frac{z^2}{c^2} = 1$$




FIGURE 4 – Représentation 3D avec fonction uniforme

la méthode consiste à générer des points aléatoires et à ne garder que ceux qui satisfont $\frac{x^2}{a^2} + \frac{y^2}{b^2} + \frac{z^2}{c^2} \leq 1$, les autres sont rejetés. On obtient ainsi un nuage de points uniformément réparti à l'intérieur de l'ellipsoïde, et on peut visualiser l'alignement des vecteurs propres de la matrice de covariance avec ses axes.




FIGURE 5 – Représentation 3D Ellipsoïde

3.2.3 Expérience 3

La 3^{ème} expérience portait sur la régularisation de la matrice de covariance par shrinkage, dans le contexte du problème MPT (Modern Portfolio Theory) de Markowitz [5]. L'idée de base est que la matrice de covariance empirique Σ_{emp} est une estimation bruitée de la vraie matrice Σ (surtout quand le nombre d'observations n'est pas loin du nombre d'actifs). Le shrinkage [3] [4] consiste à "tirer" cette matrice empirique vers une matrice cible T plus simple, avec

$$\hat{\Sigma} = (1 - \lambda)\Sigma_{emp} + \lambda T,$$

avec $\lambda \in [0, 1]$

Pour mettre en place cette expérience, j'ai d'abord simulé une vraie matrice de covariance Σ (construite de façon à être symétrique définie positive), puis généré $T = 50$ observations gaussiennes selon cette covariance pour $n = 3$ actifs, et calculé la matrice de covariance empirique Σ_{emp} à partir de ces données.

Phase 1 : Shrinkage et choix de la cible. J'ai testé plusieurs matrices cibles T : $T = \sigma^2 Id$ (avec σ^2 la variance moyenne empirique), $T = \text{diag}(\Sigma_{emp})$ (ne garde que les variances, supprime les corrélations), et $T = Id$. Pour chaque cible et pour λ variant de 0 à 1, j'ai calculé la distance de Frobenius entre $\hat{\Sigma}$ et la vraie matrice Σ . Cela permet de voir quelle cible permet de rapprocher le plus la matrice régularisée et la vraie matrice, et pour quelle valeur de λ (Figure 6). Dans mon cas, la cible $T = \sigma^2 Id$ semblait donner les meilleurs résultats, avec une distance à Sigma minimum autour de $\lambda \approx 0.6$.




FIGURE 6 – Comparaison des matrices cibles

J'ai aussi regardé l'effet du shrinkage sur les valeurs propres de $\hat{\Sigma}$ en fonction de λ (toujours avec $T = \sigma^2 Id$) (Figure 7). J'ai observé que les petites valeurs propres augmentaient et les grandes diminuaient à mesure que λ augmentait. Cela montre que le shrinkage "aplatit" le spectre vers celui de la cible. À $\lambda = 1$, on retombait sur les valeurs propres de T , toutes égales entre elles.




FIGURE 8 – Courbe d'erreur moyenne selon λ obtenue par cross-validation




FIGURE 7 – Déformation des valeurs propres par shrinkage

Phase 2 : Choix de λ par validation croisée. Afin de trouver le λ "optimal" j'ai ensuite mis en place une validation croisée de type Monte-Carlo [6] : on découpe aléatoirement les données en un échantillon d'entraînement (80%) et un échantillon de validation (20%), on calcule $\hat{\Sigma}$ sur l'entraînement pour chaque λ , et on mesure la distance de Frobenius entre $\hat{\Sigma}$ et la covariance empirique de l'échantillon de validation. On répète ça 200 fois et on fait la moyenne de l'erreur pour chaque λ , on obtient une courbe d'erreur moyenne en fonction de λ (Figure 8), et son minimum est le λ optimal empirique, ici 0.78 .

Phase 3 : Choix analytique de λ (Ledoit-Wolf). Enfin, j'ai estimé λ^* avec la formule de Ledoit-Wolf [2] :

$$\lambda^* = \frac{\text{bruit de } \Sigma_{emp}}{\text{distance entre } \Sigma_{emp} \text{ et } T}$$

où le bruit est estimé par $\frac{1}{T} \sum_{t=1}^T \|x_t x_t^\top - \Sigma_{emp}\|_F^2$, et le dénominateur est la distance de Frobenius au carré entre Σ_{emp} et la cible T . J'ai obtenu $\lambda \approx 0.68$. J'ai comparé le λ^* obtenu par cette formule et celui trouvé par *cross-validation* sur la courbe de distance entre Σ_{shrink} et Σ en fonction de λ (Figure 9). Et j'ai observé que dans

mon cas, le λ trouvé par la méthode de Ledoit-Wolf était meilleur et qu'il se situait bien dans une zone raisonnable (proche du minimum de la vraie distance).




FIGURE 9 – Comparaison des estimations de lambda

Finalement, cette troisième expérience m'a permis de visualiser concrètement comment le shrinkage agit sur le spectre de la matrice de covariance, et de comparer deux approches pour choisir le paramètre de régularisation λ : une approche empirique par validation croisée, et une approche analytique (Ledoit-Wolf).

3.2.4 Expérience 4

La 4^{ème} expérience reposait sur un problème concret en finance de marchés : que faire quand les actifs de la matrice n'ont pas tous le même historique de données ? Par exemple, si on constitue un portefeuille avec des actions du CAC 40 ou du SP 500, certains titres ont des historiques très anciens, alors que d'autres, introduits plus récemment en bourse, n'ont que quelques années de données disponibles.

Dans ce cas là, l'estimation empirique classique de la matrice de covariance, dite "complète", n'est pas adaptée car elle tronque toutes les séries à la longueur la plus courte, ce qui peut causer une lourde perte d'information.

Cette expérience s'appuie sur les travaux de Stambaugh (1997)[7] et Gramacy, Lee et Silva (2009) [1], qui présentent des méthodes de régression pour exploiter toutes les données disponibles malgré les longueurs d'historiques inégales.

J'ai généré une matrice de $m = 10$ actifs avec un historique maximum de $n = 100$ observations, en imposant un schéma de données manquantes monotone (bibliothèque `monomvn`) : les actifs les plus récents ont moins d'observations, ce qui donne une structure en escalier bien visible sur la figure 10.




FIGURE 10 – Matrice d'actifs avec des historiques inégaux

J'ai estimé la matrice de covariance avec quatre méthodes disponibles dans la bibliothèque `monomvn` : PCR (principal component regression), PLSR (Partial least squares regression), Lasso et Ridge, que j'ai comparées à l'estimateur "complet". Pour évaluer la qualité de chaque estimateur par rapport à la vraie matrice Σ , j'ai utilisé la norme de Frobenius et la divergence de Kullback-Leibler [1] :

$$KL(\hat{\Sigma}||\Sigma) = \frac{1}{2} \left(\log \frac{|\hat{\Sigma}|}{|\Sigma|} + \text{tr}(\hat{\Sigma}^{-1}\Sigma) + (\hat{\mu} - \mu)^{\top} \hat{\Sigma}^{-1}(\hat{\mu} - \mu) \right)$$

J'ai ensuite répété l'expérience 200 fois pour avoir des résultats moyennés stables (Table 1). Sur la divergence KL, PCR obtient les meilleures performances (466 en moyenne), tandis que Lasso (2 286), PLSR (710) et surtout Ridge (40 782) s'en sortent beaucoup moins bien. L'estimateur complet est également très mauvais (9 722), ce qui confirme que la méthode de troncature des séries déforme la matrice. En revanche, sur l'écart-type du portefeuille, Lasso (0.83) et PCR (0.71) sont assez proches. Finalement, sur la norme de Frobenius, les écarts entre les différentes méthodes sont très faibles : toutes se situent entre 36.5 et 36.9, avec cette fois l'estimateur de Lasso qui obtient la meilleure distance.

Le screeplot (figure 11) montre que les méthodes ne se comportent pas toutes pareil sur les premières valeurs propres. Lasso colle bien la vraie courbe dès le rang 1, alors que PCR et Ridge ont un grand écart sur la première

Méthode	KL moyen	Ecart-type moyen	Frobenius moyen
Complète	9722.06	1.14	36.84
LASSO	2291.69	0.83	36.45
PCR	466.28	0.71	36.55
PLSR	710.16	0.79	36.56
RIDGE	40782.28	0.99	36.52

TABLE 1 – Tableau de comparaison des méthodes de régression

valeur propre avant de rattraper à partir du rang 2. L'estimateur complet est le plus en retard : il ne suit la vraie courbe qu'à partir du rang 3, ce qui illustre bien la perte d'information due à la troncature. La figure 12 confirme ça : l'erreur est surtout concentrée sur les premiers rangs, et c'est Lasso qui s'en sort le mieux sur la première valeur propre, contrairement à ce que ses résultats sur la KL pourraient laisser penser. À partir du rang 4-5, toutes les méthodes convergent vers une erreur proche de zéro.




FIGURE 11 – Screeplot avec les différentes méthodes de regression




FIGURE 12 – Erreur sur les valeurs propres selon la méthode de régression

Pour finir, j'ai visualisé avec **RGL** les vecteurs propres des matrices de covariance estimées (Figure 13). On observe que les vecteurs propres de Lasso et de PCR sont identiques, leurs flèches sont confondues. Cela signifie qu'avec

3 actifs, les deux méthodes identifient les mêmes directions de variation dans les données. Concrètement, Lasso se trompe sur l'amplitude des variations, mais retrouve quand même les bons axes. C'est pour ça qu'il arrive à construire un portefeuille avec un écart-type correct (Table 1). L'estimateur complet, lui, a un vecteur propre principal (vp1 en orange) qui part dans une direction très différente des autres, ce qui illustre bien la faiblesse de l'estimateur complet.




FIGURE 13 – Représentation 3D des vecteurs propres des matrices de covariance

4 Bilan du stage

4.1 Utilité

Ce stage s'inscrivait dans un cadre assez particulier. Mon tuteur est chercheur en géométrie à la base, mais il enseigne aussi en finance des marchés, d'où le fait que le stage se situe à la croisée des deux domaines. La problématique n'est pas tout à fait la même selon le domaine : en géométrie, on s'intéresse aux vecteurs propres et à la décomposition spectrale, alors qu'en finance l'approche est plus structurelle, centrée sur la construction de portefeuilles.

Concrètement, mon tuteur donne un cours de mise en oeuvre de la théorie de Markowitz (MPT) dans le master Finance, parcours Marchés Financiers, de l'IAE de Clermont-Ferrand. Et il souhaite, pour l'année prochaine, prolonger ce cours en y intégrant une partie plus mathématique, sur l'estimation des matrices de covariance. Avant de le faire, il voulait tester la faisabilité du contenu, voir si les étudiants pourraient suivre sans trop de difficultés.

Et dans ce contexte, ayant un profil plus mathématique et informatique que les étudiants de master finance, l'idée était d'observer ma réaction et mon travail face à ces expériences. Cela afin d'avoir une analyse objective de la façon dont quelqu'un en formation réagit face à ce contenu. Le raisonnement est que si j'y arrive, il y a de bonnes chances qu'eux aussi.

L'objectif fixé au départ était de compléter les trois premières expériences, couvrant la prise en main des valeurs propres et vecteurs propres, l'étude géométrique sur nuages de points 3D, et l'introduction du shrinkage avec l'estimateur de Ledoit-Wolf. J'ai réussi à les mener toutes les trois à bien, et j'ai même pu aller plus loin en réalisant une quatrième expérience, portant sur l'application de ces méthodes à la gestion de portefeuille avec des durées d'historiques différentes via la théorie de Markowitz.

4.2 Apports

Ce stage m'a beaucoup apporté et pour plusieurs aspects.

D'un point de vue technique d'abord, j'ai découvert et utilisé des outils que je ne connaissais pas, comme Git (dont le lien est en annexe), ou de nouvelles librairies R (`RGL`, `MASS`, `gganimate`, `monomvn`). Beaucoup de notions vues en licence ont refait surface pendant ces 7 semaines : l'optimisation, l'économétrie, la régression linéaire, l'algèbre, l'analyse, le cours de R, de Risque et incertitude etc., et j'ai pu les approfondir en les appliquant à des problèmes concrets. Le fait de travailler avec des données générées aléatoirement m'a aussi beaucoup aidée : pouvoir relancer les simulations, observer les changements et voir les phénomènes évoluer en fonction des tirages, ça donne une compréhension vraiment plus profonde de ce qu'on manipule.

Mon tuteur m'a laissé beaucoup d'autonomie, ce que j'ai beaucoup apprécié. Il m'encourageait à explorer, à ajouter des éléments quand j'étais curieuse, à aller au-delà de ce qui était demandé. Ce cadre de liberté a rendu le stage vraiment enrichissant, parce que j'apprenais vraiment pour apprendre, pas juste pour cocher des cases.

5 Conclusion

Ce stage de 7 semaines au LIMOS a été une très bonne expérience, à la fois sur le plan technique et humain. J'ai pu travailler sur un sujet intéressant et concret, découvrir des méthodes que je ne connaissais pas, et progresser sur des notions qui me seront utiles pour la suite, notamment en master.

Au-delà du contenu mathématique, j'ai trouvé la façon de travailler très enrichissante : l'autonomie, la liberté d'explorer, les échanges avec mon tuteur et avec les autres stagiaires. C'était aussi ma première expérience des mathématiques en dehors du cadre scolaire, sans cours ni exercices mais avec un vrai problème ouvert à creuser.

Ce stage m'a donné une image concrète et très positive de ce que peut être la recherche, et souhaitant m'orienter vers la recherche en biostatistique, ça m'a rassurée dans mes choix pour la suite. Cette expérience clôt bien ces trois années de licence, et m'a permis de me préparer au stage de master approchant.

Références

- [1] Robert B. GRAMACY, Joo Hee LEE et Ricardo SILVA. *On estimating covariances between many assets with histories of highly variable length*. 2009. arXiv : 0710.5837 [stat.ME]. URL : <https://arxiv.org/abs/0710.5837>.
- [2] Olivier LEDOIT et Michael WOLF. “A well-conditioned estimator for large-dimensional covariance matrices”. In : *Journal of Multivariate Analysis* 88.2 (2004), p. 365-411. ISSN : 0047-259X. DOI : [https://doi.org/10.1016/S0047-259X\(03\)00096-4](https://doi.org/10.1016/S0047-259X(03)00096-4). URL : <https://www.sciencedirect.com/science/article/pii/S0047259X03000964>.
- [3] Olivier LEDOIT et Michael WOLF. “Honey, I shrunk the sample covariance matrix”. In : *Journal of Portfolio Management* 30.4 (2004), p. 110-119.
- [4] Olivier LEDOIT et Michael WOLF. “Improved estimation of the covariance matrix of stock returns with an application to portfolio selection”. In : *Journal of Empirical Finance* 10.5 (2003), p. 603-621. ISSN : 0927-5398. DOI : [https://doi.org/10.1016/S0927-5398\(03\)00007-0](https://doi.org/10.1016/S0927-5398(03)00007-0). URL : <https://www.sciencedirect.com/science/article/pii/S0927539803000070>.
- [5] Harry MARKOWITZ. “Portfolio Selection”. In : *The Journal of Finance* 7.1 (1952), p. 77-91. ISSN : 00221082, 15406261. URL : <http://www.jstor.org/stable/2975974> (visité le 16/06/2026).
- [6] Richard SIMON. “Resampling Strategies for Model Assessment and Selection”. In : avr. 2007, p. 173-186. ISBN : 978-0-387-47508-0. DOI : 10.1007/978-0-387-47509-7_8.
- [7] Robert F. STAMBAUGH. “Analyzing investments whose histories differ in length”. In : *Journal of Financial Economics* 45.3 (1997), p. 285-331. ISSN : 0304-405X. DOI : [https://doi.org/10.1016/S0304-405X\(97\)00020-2](https://doi.org/10.1016/S0304-405X(97)00020-2). URL : <https://www.sciencedirect.com/science/article/pii/S0304405X97000202>.

Annexes

Dépôt GitHub

Le Git du stage est disponible à l'adresse suivante :

<https://github.com/joannamclt/Joanna>

Résumé

Ce rapport présente le stage de 7 semaines que j'ai effectué au Laboratoire d'Informatique, de Modélisation et d'Optimisation des Systèmes à Clermont-Ferrand. Il portait sur les méthodes d'estimation de la matrice de covariance et leur impact sur ses valeurs et vecteurs propres, avec deux applications : la gestion de portefeuille en finance et la géométrie des surfaces.

Le stage était organisé en quatre expériences progressives. La première portait sur la convergence de l'estimateur empirique de la matrice de covariance. La deuxième étudiait les valeurs propres et les vecteurs propres de la matrice et leur lien avec la normale à un nuage de points 3D. La troisième introduisait la régularisation par shrinkage et comparait la validation croisée à l'estimateur de Ledoit-Wolf pour choisir le paramètre de régularisation. La quatrième s'intéressait au problème des actifs aux historiques inégaux, en testant plusieurs méthodes de régression (PCR, PLSR, Lasso, Ridge).